

因果推論で推薦システムを問い直す

@CFML勉強会 #1

東京工業大学 経営工学系 B4

齋藤 優太


自己紹介

自己紹介



usaito

(@moshumoshu1205)



ここ出身（北海道根室市）

所属：

- 東京工業大学 経営工学系 B4
- **Cyberagent AI Lab ADEcon** Research Intern
- **So-net Media Networks a.i lab.** Research Intern

研究・興味分野：

- CFML, Domain Adaptation, Information Retrieval

活動等：

- 論文: SDM19採択 (acceptance rate: 22.7%)
- Blog: 『Counterfactualを知りたい』

イントロダクション

Recommendation x Causalityへの注目

情報検索・推薦系のTop Conferenceで高く評価



推薦システムのオフライン評価

Best Paper Honorable Mentions

Unsubscription: A Simple Way to Ease Overload in Email

Iftah Gamzu, Liane Lewin-Eytan and Natalia Silberstein

Offline A/B testing for recommender systems

Alexandre Gilotte, Clement Calauzenes, Thomas Nedelec, Alexandre Abraham and Simon Dolle

2018

- Causal Embeddings for Recommendation
by S. Bonner, F. Vasile (Best Long Paper)
- Generation Meets Recommendation: Proposing Novel Items for Groups of Users
by T.V. Vo, H. Soh (Best Long Paper Runner-up)




オフライン学習アルゴリズム

Recommendation x Causalityへの注目

推薦周りの5つのトレンドの一つ

Recent Trend in Personalization A Netflix Perspective @ICML19



Artwork for Stranger Things that each receive over 5% of impressions from our personalization algorithm. Different images cover a breadth of themes in the show to go beyond what any single image portrays.

Trending Now

Some recent trends in approach

1. Deep Learning
2. Causality
3. Bandits & Reinforcement Learning
4. Fairness
5. Experience Personalization

Trend 2: Causality



NETFLIX


推薦のバンディットのオフライン評価

Artwork Personalization at Netflix

Justin Basilico: Recent Trends in Personalization: A Netflix Perspective. Adaptive and Multi-Task Learning Workshop. In ICML 2019.

推薦システムに存在するバイアス


Feedback Loopに起因する従来の推薦システムの問題点



ログデータに対して良く予測出来る
Policyを良しとする

推薦システムに存在するバイアス

Feedback Loopに起因する従来の推薦システムの問題点



ログデータに対して良く予測出来る
Policyを良しとする

観測されるデータは過去の方策に依存

ただし、

$$\text{ログデータ} \sim \pi^{\text{past}}(p_j | u_i)$$

観測データの偏りにより生じる問題

真のRating

過去の推薦方策

Y	Horror Romance Drama			p	Horror Romance Drama		
	Horror	Romance	Drama		Horror	Romance	Drama
Horror Lovers	5	1	3		p	p/10	p/2
Romance Lovers	1	5	3		p/10	p	p/2

\hat{Y}_1				\hat{Y}_2			
	Horror	Romance	Drama		Horror	Romance	Drama
Horror Lovers	5	1	5		5	5	3
Romance Lovers	1	5	5		5	5	3

予測 1

予測 2

- ユーザー属性
 - Horror Lovers
 - Romance Lovers
- 映画ジャンル
 - Horror · Romance · Drama

属性とジャンルの組み合わせに依存してratingが決まるとする

観測データの偏りにより生じる問題

真のRating

過去の推薦方策

Y	Horror	Romance	Drama
Horror Lovers	5	1	3
Romance Lovers	1	5	3

p	Horror	Romance	Drama
Horror Lovers	p	$p/10$	$p/2$
Romance Lovers	$p/10$	p	$p/2$

予測1と予測2の真のRatingに対する予測誤差を正確に知りたい

\hat{Y}_1	Horror	Romance	Drama
Horror Lovers	5	1	5
Romance Lovers	1	5	5

\hat{Y}_2	Horror	Romance	Drama
Horror Lovers	5	5	3
Romance Lovers	5	5	3

予測 1

予測 2

観測データの偏りにより生じる問題

真のRating				過去の推薦方策			
Y	Horror	Romance	Drama	p	Horror	Romance	Drama
	Horror Lovers	Romance Lovers			Horror Lovers	Romance Lovers	
	5	1	3		p	p/10	p/2
	1	5	3		p/10	p	p/2
\hat{Y}_1	Horror Lovers	Romance Lovers		\hat{r}_2	Horror Lovers	Romance Lovers	
	Horror Lovers	Romance Lovers			Horror Lovers	Romance Lovers	
	5	1	5		5	5	3
	1	5	5		5	5	3
予測 1				予測 2			

ただし各データは
過去の推薦方策に依存して
観測確率がバラバラ

推薦システムに存在するバイアス

真のRating		過去の推薦方策	
Y	Horror Romance Drama	p	Horror Romance Drama
Horror Lovers	5 1 3	p $p/10$ $p/2$	
Romance Lovers	1 5 3	$p/10$ p $p/2$	
\hat{Y}_1		\hat{Y}_2	
Horror Lovers	5 1 5	5 5 3	
Romance Lovers	1 5 5	5 5 3	
予測 1		予測 2	

3200回推薦

それぞれの観測回数

	Horror	Romance	Drama
Horror Lovers	1000	100	500
Romance Lovers	100	1000	500

MAEによる評価

	True	MNAR
予測1	0.67	0.62
予測2	1.33	0.25

評価にバイアスが生じている

分布の偏りは実際に存在する

そもそもアイテムの観測数には大きな違いが見られる
(Most Popular推薦などではこの傾向が顕著)

3つの標準的なデータセットでの検証結果

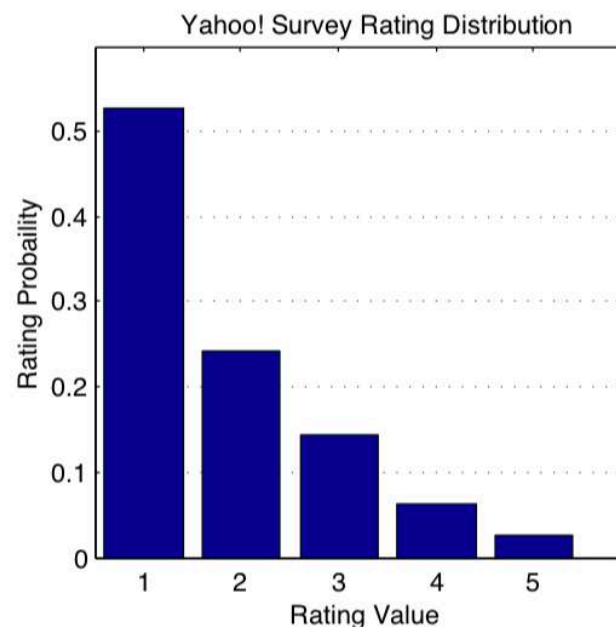


Figure 2: The distribution of n_i^* (the observed number of interactions with item i) in the three datasets. The items are presented in descending order of n_i^* . The horizontal axis is log scaled for better visualization. In all datasets, the n_i^* distribution is skewed and the user interactions are significantly biased.

分布の偏りは実際に存在する

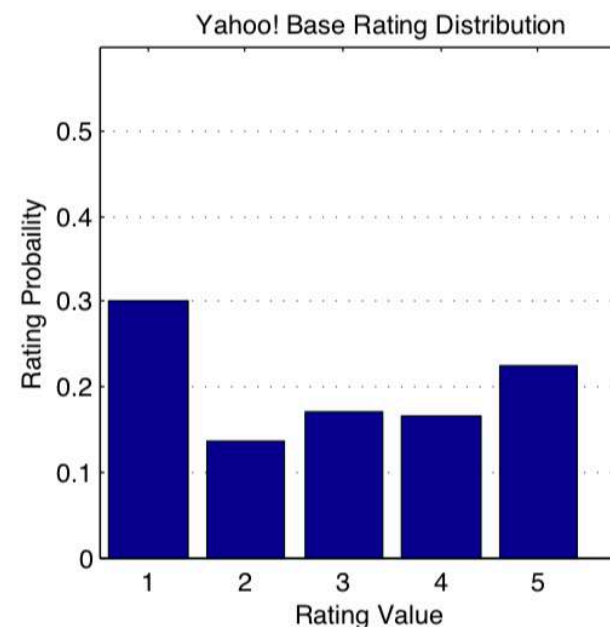
真のrating分布とログデータにおけるrating分布は大きく乖離

実際のrating分布



(a) Yahoo! Survey Rating Distribution

観測されたrating分布



(b) Yahoo! Base Rating Distribution

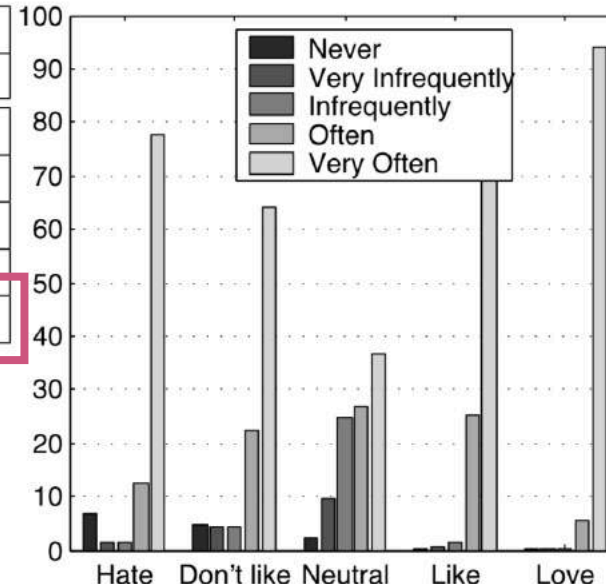
分布の偏りは実際に存在する

ユーザーは明確な好き嫌いがあるitemをrateしやすい

→ 結果として高いratingが観測されやすくなる

選好度合い

Rating Frequency	Preference Level				
	Hate	Don't like	Neutral	Like	Love
Never	6.76%	4.69%	2.33%	0.11%	0.07%
Very Infrequently	1.59%	4.17%	9.46%	0.54%	0.35%
Infrequently	1.63%	4.44%	24.87%	1.48%	0.20%
Often	12.46%	22.50%	26.82%	25.30%	5.46%
Very Often	77.56%	64.20%	36.50%	72.57%	93.91%



rateの
しやすさ

Survey Results: Yahoo! LaunchCast users were asked to report the frequency with which they choose to rate a song given their preference for that song. The data above show the distribution over rating frequencies given several preference levels. Users could select only one rating frequency per preference level.

ここまでのまとめ

推薦システムで観測されるデータは、

- 自分たちが使っていた「過去の推薦方策」
- ユーザーによる「rating付与の自己選択」

という大きく2つの要因により、実際の分布と乖離している

ここでの本当の主題

因果推論で推薦システムを問い直す



因果推論と同様の手法で推薦システムを問い直す

- これまで紹介した話に因果要素は特になし
- 因果推論は分布の乖離がキーになる分野の一つ
- “因果”ではなく“分布の乖離”をどう扱うかを議論

分布の乖離の補正方法

推薦システムの学習・評価の定式化

ratingの予測値集合 $\hat{Y} = \left\{ \hat{Y}_{u,i} \right\}_{(u,i)}$ の**真の損失**を次のように定義する

$$\mathcal{L}(\hat{Y}) = \frac{1}{U \cdot I} \sum_{u,i} \delta \left(Y_{u,i}, \hat{Y}_{u,i} \right)$$

全ユーザーとアイテムにおける平均
(テスト環境は離散一様分布と想定)

MSEなどの局所損失

最初に最適化したいものを明らかにすべき

個人的な意見ですが、

最初に**自分にとっての真の損失**を定めることが**最重要**

- 特に**どの分布に対してworkさせたいのか**
(先の例ではuserとitemが一様に分布している環境)
- これを意識することで、**分布の乖離に自覚的**になる

Recommendation x Causalityの目標

その上で達成したい目標は、

自分の持っている分布 を用いてalgorithmが
過去のpolicy等に依存した観測データ

workしてほしい分布 における損失の正確な推定
(今回は) 離散一様なユーザー・アイテム分布

- 評価の場合：真の損失の推定値を用いて予測の良さを評価する
- 学習の場合：真の損失の推定値をもとにモデルパラメータを更新

観測データの定式化

観測有無を表す確率変数 $O_{u,i}$ を導入 (観測構造に依らない定式化)

観測されるデータは $\{(u, i, Y_{u,i}) : O_{u,i} = 1\}$ と表される

損失を単に平均する **Naive推定量** がよく使われていると思われる

$$\hat{\mathcal{L}}_{naive}(\hat{Y}) = \frac{1}{\sum_{u,i} O_{u,i}} \sum_{\substack{(u,i): O_{u,i}=1 \\ \text{観測されたデータ}}} \delta(Y_{u,i}, \hat{Y}_{u,i})$$

バイアスの原因 (Propensity Overfitting)

Naive推定量の期待値をとると...

$$\begin{aligned}\mathbb{E}_O \left[\hat{\mathcal{L}}_{naive}(\hat{Y}) \right] &= \mathbb{E}_O \left[\frac{1}{N} \sum_{u,i} O_{u,i} \cdot \delta \left(Y_{u,i}, \hat{Y}_{u,i} \right) \right] \\ &= \frac{1}{N} \sum_{u,i} \mathbb{E}_{O_{u,i}} [O_{u,i}] \cdot \delta \left(Y_{u,i}, \hat{Y}_{u,i} \right) \\ &= \frac{1}{N} \sum_{u,i} P_{u,i} \cdot \delta \left(Y_{u,i}, \hat{Y}_{u,i} \right) \neq \underline{\mathcal{L}(\hat{Y})} \\ &\quad \text{biased!!}\end{aligned}$$

バイアスの発生原因

Naive推定量の期待値をとると...

$$\mathbb{E}_O \left[\hat{\mathcal{L}}_{naive}(\hat{Y}) \right] = \mathbb{E}_O \left[\frac{1}{N} \sum_{u,i} O_{u,i} \cdot \delta \left(Y_{u,i}, \hat{Y}_{u,i} \right) \right]$$

(暗黙のうちに)

傾向スコアで重み付けた

評価や学習に陥ってしまう

$$= \frac{1}{N} \sum_{u,i} \mathbb{E}_{O_{u,i}} [O_{u,i}] \cdot \delta \left(Y_{u,i}, \hat{Y}_{u,i} \right)$$

$$= \frac{1}{N} \sum_{u,i} P_{u,i} \cdot \delta \left(Y_{u,i}, \hat{Y}_{u,i} \right) \neq \mathcal{L}(\hat{Y})$$

Inverse Propensity Score (IPS)

観測確率による暗黙の重み付けを回避するために、
あらかじめデータの観測確率の逆数で損失を重み付けておく

損失に対するIPS推定量 [Schnabel et al, 2016]

$$\hat{\mathcal{L}}_{IPS}(\hat{Y}) = \frac{1}{U \cdot I} \sum_{\substack{(u,i): O_{u,i}=1 \\ \text{観測データのみで構成}}} \frac{\delta(Y_{u,i}, \hat{Y}_{u,i})}{\underbrace{P_{u,i}}_{\text{傾向スコア}}}$$

IPS推定量は不偏性を満たす

IPS推定量の期待値をとると...

$$\begin{aligned}\mathbb{E}_O \left[\hat{\mathcal{L}}_{IPS}(\hat{Y}) \right] &= \mathbb{E}_O \left[\frac{1}{U \cdot I} \sum_{u,i} O_{u,i} \cdot \frac{\delta(Y_{u,i}, \hat{Y}_{u,i})}{P_{u,i}} \right] \\ &= \frac{1}{U \cdot I} \sum_{u,i} \frac{\mathbb{E}_{O_{u,i}} [O_{u,i}]}{P_{u,i}} \cdot \delta(Y_{u,i}, \hat{Y}_{u,i}) \\ &= \frac{1}{U \cdot I} \sum_{u,i} \delta(Y_{u,i}, \hat{Y}_{u,i}) = \underline{\mathcal{L}(\hat{Y})} \\ &\quad \text{unbiased!!}\end{aligned}$$

**Biasの観点では
IPS推定量を使うべき**

IPS推定量を用いた推薦システムの学習

学習の場合：IPS損失+正則化項をmini-batchで最小化

$$\operatorname{argmin}_{V, W, A} \left[\underbrace{\sum_{O_{u,i}=1} \frac{\delta_{u,i} (Y, V^\top W + A)}{P_{u,i}}}_{\text{重み付け損失}} + \underbrace{\lambda (\|V\|_F^2 + \|W\|_F^2)}_{\text{正則化項}} \right]$$

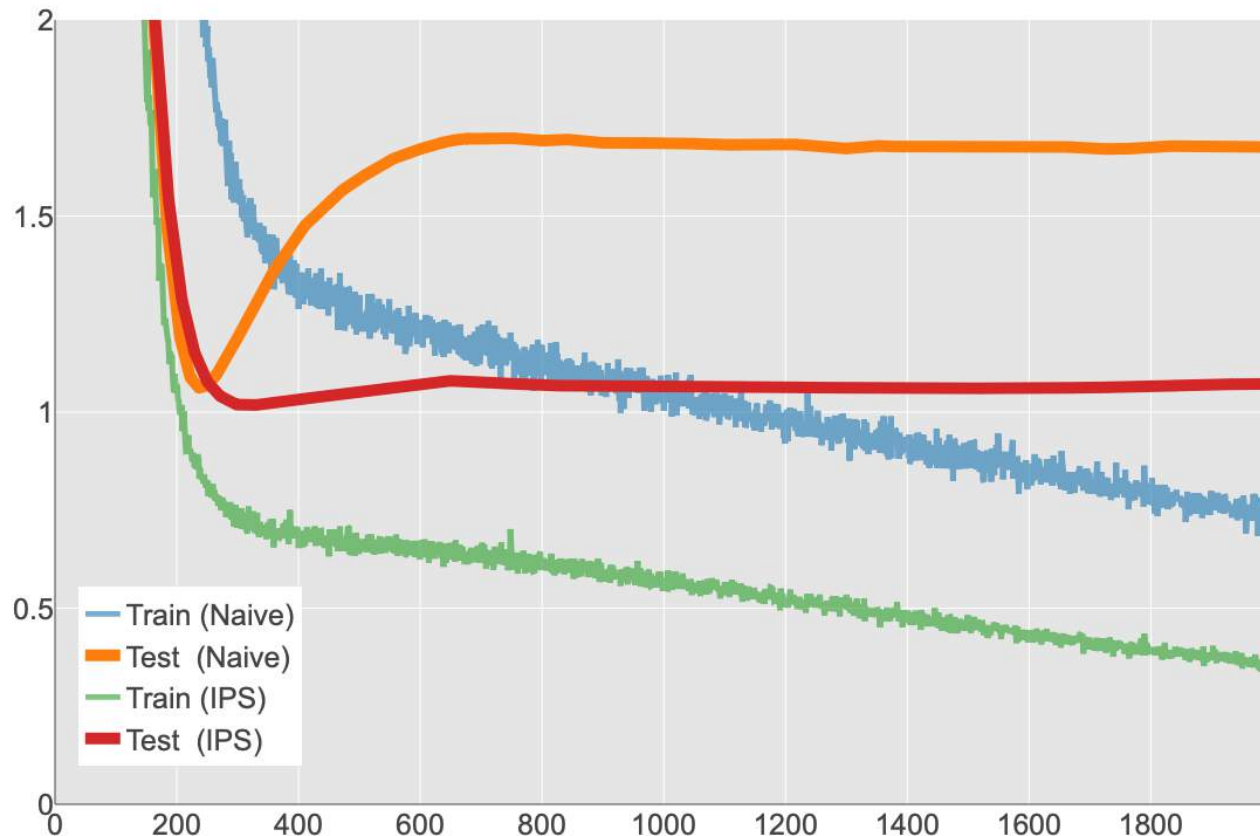
パラメータ更新則：

$$V_u \leftarrow V_u + \eta \left(\underbrace{\left(\sum_{i \in \mathcal{I}_{\text{mini}}} \frac{err_{u,i}}{P_{u,i}} W_i \right)}_{\text{重み付け損失}} - \underbrace{\lambda V_u}_{\text{正則化項}} \right)$$

実験: NaiveなMFは過学習

TrainとTestの分布が異なるYahoo! R3データを用いて学習

Train (薄) と Test(濃) におけるMSE




NaiveなMFは学習の
途中から**Test lossのみ悪化**

[Schnabel et al., 2016]の追試

実験: IPSに基づいたMFは過学習を軽減

TrainとTestの分布が異なるYahoo! R3データを用いて学習

Train (薄) と Test(濃) におけるMSE



UnbiasedなMFはTestとは
分布の異なる**Trainデータ**を
うまく補正しながら学習

[Schnabel et al., 2016]の追試

まとめ

- 推薦システムで観測されるデータは、ユーザーの選択や過去の推薦方策によって偏ったデータになっている
- 単純に損失を平均するNaive推定量を用いると暗黙のうちに観測されやすいデータに対しOverfitしてしまう
- 傾向スコアの逆数で事前に重み付け(IPS)することにより偏りを除去した学習や評価が可能になる

ご静聴ありがとうございました。

References

[Schnabel et al., 2016]: Tobias Schnabel, Adith Swaminathan, Ashudeep Singh, Navin Chandak, and Thorsten Joachims. Recommendations as treatments: Debiasing learning and evaluation. In *Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48*, ICML'16, pages 1670–1679, 2016.

[Bonner et al., 2018]: Stephen Bonner and Flavian Vasile. Causal embeddings for recommendation. In *Proceedings of the 12th ACM Conference on Recommender Systems*, pages 104–112. ACM, 2018.

[Liang et al., 2016]: Dawen Liang, Laurent Charlin, James McInerney, and David M Blei. Modeling user exposure in recommendation. In *Proceedings of the 25th International Conference on World Wide Web*. 951–961.

[Wang et al., 2018]: Yixin Wang, Dawen Liang, Laurent Charlin, David M Blei. The deconfounded recommender: A causal inference approach to recommendation. arXiv preprint arXiv:1808.06581 .

[Yang et al., 2018]: Longqi Yang, Yin Cui, Yuan Xuan, Chenyang Wang, Serge Belongie, and Deborah Estrin. 2018. Unbiased Offline Recommender Evaluation for Missing- Not-At-Random Implicit Feedback. In *Twelfth ACM Conference on Recommender Systems (RecSys'18)*

[Marlin et al., 2007]: Benjamin M. Marlin, Richard S. Zemel, Sam Roweis, and Malcolm Slaney. Collaborative filtering and the missing at random assumption. In *UAI*, pp. 267–275, 2007.