

Counterfactual Machine Learningの概要 (反実仮想機械学習)

2019/07/29 @Sony R&D

東京工業大学 経営工学系 B4

齋藤 優太

本日のお話の流れ

CounterFactual Machine Learningの概要 (25min) :


- 分野の盛り上がりと応用例
- 検索システムにおける応用例
- **推薦システムにおけるCFML (25min) :**
 - 推薦システムに潜在するバイアス
 - バイアス除去の基礎理論と簡易実験

CFMLの盛り上がり

実はトップカンファで多くのWorkshopが開催

RecSys 2018,19

「Offline evaluation for recsys」



Asking the right question is half the answer: Revisiting the choice of offline metrics for recommender systems.

Recommender systems are notoriously hard to evaluate due to their interactive and dynamic nature. When evaluating their systems, practitioners often observe significant differences between offline results and online results of a new algorithm, and therefore tend to mostly rely on online methods such as A/B testing to evaluate their algorithms.

This is unfortunate because online evaluation is not always possible and often expensive. Offline evaluation, on the other hand, provides a scalable way of comparing recommender systems and helps bridge the gap between academia and industry in the field of recommendation at large.

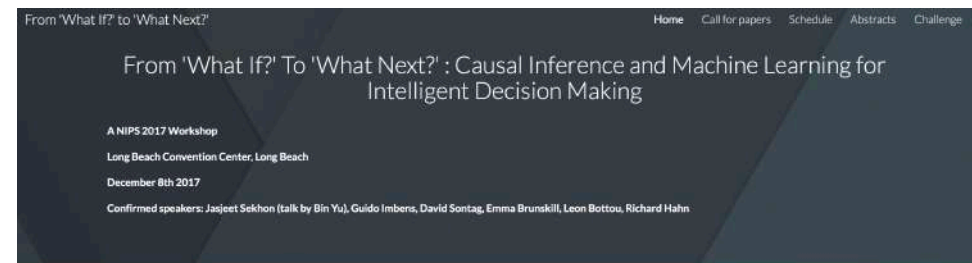
In the past, recommender systems have been evaluated using proxy offline metrics coming from supervised methods, such as regression metrics (mean squared error, log likelihood), classification metrics (area under precision/recall curve) or ranking metrics (precision@k, normalized discounted cumulative gain).

Recent research on recommender systems makes the link with the work on counterfactual inference and makes possible new ways to evaluate offline the quality of recommendations. In this context, we believe it is timely to organize a workshop that re-visits the problem of designing offline metrics for recommendation and makes sure the community is working on the right problem: find for each user, the most impactful recommendation.

The goal of this workshop is to foster creative discussions within the community, spanning academic and industrial backgrounds to advance the field of offline evaluation of recommender systems.

NeurIPS 2017

「What if To What Next?」



In recent years machine learning and causal inference have both seen important advances, especially through a dramatic expansion of their theoretical and practical domains. Machine learning has focused on ultra high-dimensional models and scalable stochastic algorithms, whereas causal inference has been guiding policy in complex domains involving economics, social and health sciences, and business. Through such advances a powerful cross-pollination has emerged as a new set of methodologies promising to deliver robust data analysis than each field could individually -- some examples include concepts such as doubly-robust methods, targeted learning, double machine learning, causal trees, all of which have recently been introduced.

This workshop is aimed at facilitating more interactions between researchers in machine learning and causal inference. In particular, it is an opportunity to bring together highly technical individuals who are strongly motivated by the practical importance and real-world impact of their work. Cultivating such interactions will lead to the development of theory, methodology, and - most importantly - practical tools, that better target causal questions across different domains.

In particular, we will highlight theory, algorithms and applications on automatic decision making systems, such as recommendation engines, medical decision systems and self-driving cars, as both producers and users of data. The challenge here is the feedback between learning from data and then taking actions that may affect what data will be made available for future learning. Learning algorithms have to reason about how changes to the system will affect future data, giving rise to challenging counterfactual and causal reasoning issues that the learning algorithm has to account for. Modern and scalable policy learning algorithms also require operating with non-experimental data, such as

実はトップカンファで多くのWorkshopが開催

KDD2018,19

「Offline and Online Evaluation of Interactive Systems」

2nd Workshop on Offline and Online Evaluation of Interactive Systems

25th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, August 4-8, 2019, Anchorage, Alaska - USA

- [Home](#)
- [Call for Papers](#)
- [Program](#)
- [Keynote Speakers](#)
- [Program Committee](#)

Workshop Day

August 5, 2019 (a half day workshop, from 8am till 12pm)

Workshop Objectives

While there has been a long-standing focus of empirical evaluation in building Interactive systems, new challenges have been faced by traditional evaluation methodologies to truly reflect the systems' actual online performance. This workshop aims to connect academic researchers and industrial practitioners who are working on, or interested in, online and offline evaluation of Interactive systems. The goal is to provide a forum so that industrial practitioners can expose real-world challenges and share practical experiences; academic researchers can popularize state-of-art research; and collaboration between the two can be fostered.

Topics and Themes

Topics of the workshop include, but are not limited to, the following:



NeurIPS 2019 New! 「"Do the right thing"」



Cornell University

[Home](#) [Research](#) [People](#) [Events](#) [Contacts](#) [Search](#)

NeurIPS 2019 Workshop

"Do the right thing": machine learning and causal inference for improved decision making

December 13 – 14, 2019, Vancouver

Workshop Summary

In recent years, machine learning has seen important advances in its theoretical and practical domains, with some of the most significant applications in online marketing and commerce, personalized medicine, and data-driven policy-making. This dramatic success has led to increased expectations for autonomous systems to make the right decision at the right target at the right time. This gives rise to one of the major challenges of machine learning today that is the understanding of the cause-effect connection. Indeed, actions, intervention, and decisions have important consequences, and so, in seeking to make the best decision, one must understand the process of identifying causality. By embracing causal reasoning autonomous systems will be able to answer counterfactual questions, such as "What if I had treated a patient differently?", and "What if had ranked a list differently?" thus helping to establish the evidence base for important decision-making processes.

The purpose of this workshop is to bring together experts from different fields to discuss the relationships between machine learning and causal inference and to discuss and highlight the formalization and algorithmization of causality toward achieving human-level machine intelligence.

Recommendation x Causalityへの注目

情報検索・推薦系のTop Conferenceで高く評価



推薦システムのオフライン評価

Best Paper Honorable Mentions

Unsubscription: A Simple Way to Ease Overload in Email

Iftah Gamzu, Liane Lewin-Eytan and Natalia Silberstein

Offline A/B testing for recommender systems

Alexandre Gilotte, Clement Calauzenes, Thomas Nedelec, Alexandre Abraham and Simon Dolle

2018

- Causal Embeddings for Recommendation
by S. Bonner, F. Vasile (Best Long Paper)
- Generation Meets Recommendation: Proposing Novel Items for Groups of Users
by T.V. Vo, H. Soh (Best Long Paper Runner-up)



オフライン学習アルゴリズム

先日CFML勉強会を開催。多くの申し込みが！

7月
10

CounterFactual Machine Learning勉強会 #1

募集内容

発表だけ参加

無料

先着順（抽選終了）

141/80人

発表+懇親会に参加

無料

先着順（抽選終了）

60/25人

最大時申し込み：約**250**人！

日本でも注目度が高まりつつある？

8月下旬に第二回を開催予定！

発表の詳細

タイトル：CFMLの概要と研究動向

発表者：谷口和輝 (@kazk1018)

プロフィール：現在はスタートアップでプロダクト開発と研究開発のフリーランス。元CyberAgent AILab Machine Learning Groupチームリーダー。主に機械学習・画像認識の研究開発やMLOpsなどをやっていました。

発表内容：「Counterfactual Machine Learning(CFML)」という研究分野について広く浅く紹介します。CFMLは反事実を扱う機械学習であり、Bandit Algorithmや強化学習などの分野に関連が深い研究です。この発表ではCounterfactual Machine Learningの歴史やこれまでの研究事例についてお話します。

タイトル：バンディットアルゴリズムと因果推論

発表者：安井翔太(@housecat442)

プロフィール：Cyberagent AILab ADEconチームリーダー。因果推論・計量経済学・機械学習を利用した意思決定技術の研究に取り組んでいます。

発表内容：バンディットアルゴリズムを用いて意思決定の自動化を行う事は近年様々なビジネスで適応されるようになってきました。しかし、バンディットアルゴリズムから生まれたログデータがどのような性質を持ち、どのような分析を行う事が出来るのかはあまり知られていません。この発表ではバンディットアルゴリズムのログデータを利用したPolicyの学習や因果推論への応用などについて解説します。

タイトル：因果推論で推薦システムを問い直す

発表者：齋藤優太 (@moshumoshu1205)

プロフィール：東京工業大学経営工学系B4。Cyberagent AILabとSo-net Media Networks a.i lab.でCFML関連の研究に取り組む。[ブログ](#)にてCFML関連の話題を発信中。最近の興味は教師なしドメイン適応理論。

発表内容：推薦システムや検索システムを学習・評価する際に、“データが如何に集められたか”を考慮に入れないと結果にbiasが生じてしまうことが最新の研究により明らかにされています。本発表では理論背景と簡易実験の結果を用いて推薦システムに潜むbiasの存在とその除去方法について議論します。

発表者

トリで発表しました

世界は反実仮想だらけ

Counterfactual（反実仮想的）な状況とは？

反実仮想の定義： **観測され得たけど実際には観測されなかったデータ**

例1: A/B test: Aさん  が介入群に割り当てられたとする



Counterfactual（反実仮想的）な状況とは？

反実仮想の定義： **観測され得たけど実際には観測されなかったデータ**

例1: A/B test: Aさん  が介入群に割り当てられたとする

介入を受けた時のAさん



観測可能なFactual

まさに反実仮想的な状況

介入を受けない時のAさん



観測不可能な
CounterFactual

Counterfactual（反実仮想的）な状況とは？

反実仮想の定義： **観測され得たけど実際には観測されなかったデータ**

例1: A/B test: Aさん  が介入群に割り当てられたとする

介入の
因果効果

=

介入を受けた時のAさん



観測可能なFactual

-

まさに反実仮想的な状況

介入を受けない時のAさん



観測不可能な
CounterFactual

Counterfactual（反実仮想的）な状況とは？

反実仮想の定義： **観測され得たけど実際には観測されなかった**データ

例2: Recommendation Systems

		アイテム			
		1	2	3	4
ユーザー	A	観測			
	B				観測
	C				観測
	D	観測			観測

スパースなRatingデータを使って未観測Ratingを予測

Counterfactual（反実仮想的）な状況とは？

反実仮想の定義： **観測され得たけど実際には観測されなかったデータ**

例2: Recommendation Systems

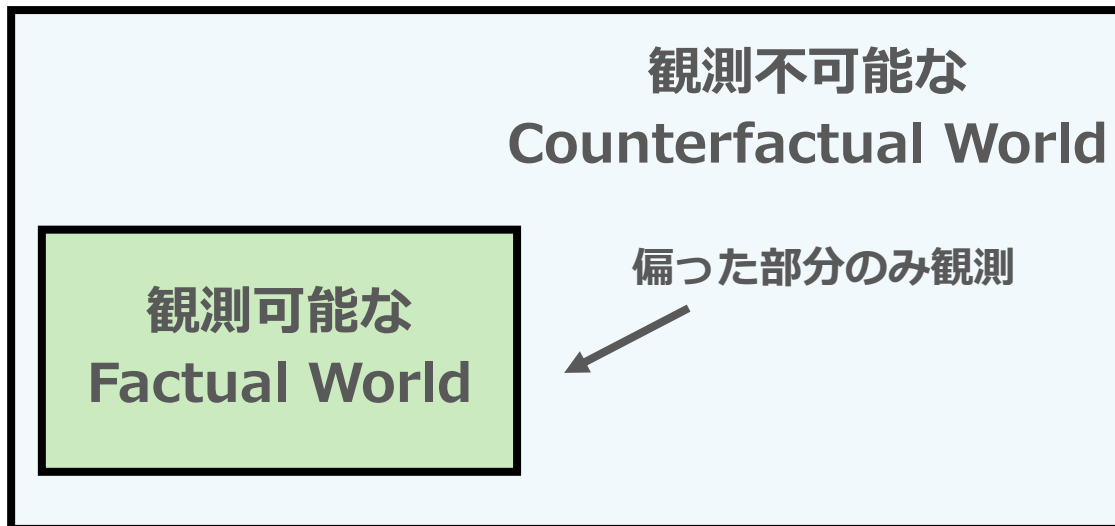
		アイテム			
		1	2	3	4
ユーザー	A	観測	未観測	未観測	未観測
	B	未観測	未観測	未観測	観測
	C	未観測	未観測	未観測	観測
	D	観測	未観測	未観測	観測

**観測されているFactualは
未観測のCounterfactualを
代表しない**ように見える

Counterfactual Machine Learningとは？

CFMLの定義：**反実仮想 (Counterfactual)** を含むログデータを用いて
アルゴリズムを適切に学習または評価するための手法群

CFMLの目的：**Counterfactualを含めた全体**を良く予測したい



私たちが目にするFactualデータは
未観測のCounterfactualを
含めた全体の望ましい代表ではない！

CFMLの応用領域

CFMLの応用可能性は無限大

- 検索エンジン（さらっと紹介）
- 推薦システム（後半の主題）
- 因果推論によるパーソナライゼーション
- バンディットアルゴリズム

etc.

*大抵の場合これらの分野と因果推論の融合と言われたりする

CFMLの応用可能性は無限大

- 検索エンジン（さらっと紹介）
- 推薦システム（後半の主題）
- 因果推論によるパーソナライゼーション
- バンディットアルゴリズム

etc.

*大抵の場合これらの分野と因果推論の融合と言われたりする

ランキング学習とは

検索クエリに対し最適なドキュメントのランキングを返したい

例) ある検索クエリに対して10個のdocumentを表示するとき

Position (k)	Ranking 1	Ranking 2
1	◎	×
2	◎	×
---	---	---
9	×	◎
10	×	◎

Ranking 1のように
関連しているdocsを
上位に表示したい
(◎だと関連性あり)

ランキング学習の定式化

損失関数をとって例えば、

関連 (relevance) の有無

$$DCG = \sum_{(q, d, r) \in \mathcal{L}_U} r \cdot \frac{1}{\text{rank}(q, d, \Omega_q)}$$

Relevantなdocumentの順位の逆数の総和を大きくしたい

$\mathcal{L}_U = \{(q, d, r)\}$: (query, document, relevance) のデータ

実際に使えるのはClickデータだけ

最適化したい損失の計算には**Relevance**が必要
しかし、コストと時間がかかるので**human annotation**はしたくない



安価に手に入る**Clickデータ**を使ってRanking Systemを構築したい

$$M = \sum_{(q, d, c) \in \mathcal{L}_U} c \cdot f(q, d, \Omega_q)$$

実際に使えるのはClickデータだけ

最適化したい損失の計算には**Relevance**が必要
しかし、コストと時間がかかるので**human annotation**はしたくない



安価に手に入るClickデータを使ってRanking Systemを構築したい

Relevanceだった部分をClickにそのまま入れ替えても大丈夫？

$$M = \sum_{(q, d, c) \in \mathcal{L}_U} c \cdot f(q, d, \Omega_q)$$

ClickはRelevanceの代わりになる？

ある検索クエリに対して10個のdocumentを表示したとき

Position (k)	Relevance	???	Click
1	◎		◎
2	×		×
---	---	---	---
9	◎		×
10	×		×

必ずしも Relevance = Click とは言えなさそう...

Position-Based Model (PBM)

ClickとRelevanceを関係付けるため次の**Position-Based Model**を導入

$$C = E \cdot R$$

かつ

C: Click

E: Examination

R: Relevance

$$\underline{P(C = 1|q, d, k)} = \underline{P(E = 1|k)} \cdot \underline{P(R = 1|q, d)}$$

Click

Examination
(positionのみに依存)

Relevance
(query-docのみに依存)

Position-Based Model (PBM)

ある検索クエリに対して10個のdocumentを表示したとき

Position (k)	Relevance	検討するか否か	
		Examine	Click
1	◎	◎	◎
2	×	◎	×
---	---	---	---
9	◎	×	×
10	×	×	×

ClickデータはExaminationの存在によってバイアスがかかっている

Inverse Propensity Approach

Relevanceだった部分をClickにそのまま入れ替えたらダメ！

$$\times \mathcal{M} = \sum_{(q,d,c) \in \mathcal{L}_U} c \cdot f(q, d, \Omega_q)$$

Inverse Propensity Approach

Relevanceだった部分をClickにそのまま入れ替えたらダメ！

$$\times M = \sum_{(q,d,c) \in \mathcal{L}_U} c \cdot f(q, d, \Omega_q)$$

Examination確率の逆数で重み付け [Joachims et al. WSDM2017]

$$M_{IPS} = \sum_{(q,d,k,c) \in \mathcal{L}} \frac{c}{\theta_k} f(q, d, \Omega_q) = \sum_{(q,d,k,\underline{c=1}) \in \mathcal{L}} \frac{1}{\theta_k} f(q, d, \Omega_q)$$

logに残ってる！

Inverse Propensity Approach

Inverse Propensityの直感的な理解

- 下のpositionにも関わらずclickが発生したデータを重要視
- 理論的にも正当性が示される

Examination確率の逆数で重み付け [Joachims et al. WSDM2017]

$$M_{IPS} = \sum_{(q,d,k,c) \in \mathcal{L}} \frac{c}{\theta_k} f(q, d, \Omega_q) = \sum_{(q,d,k,\underline{c=1}) \in \mathcal{L}} \frac{1}{\theta_k} f(q, d, \Omega_q)$$

logに残ってる！

実システムを用いた実験

設定

中国のJinri Toutiaoという
News Recommendationサイトの
Newsの提示ランキングを
click logから最適化

結果 (online A/B)

バイアスを考慮しない手法に対し
有意にCTRを改善
(トップpositionで2.6%改善)

[He et al. WWW2019]

Jinri Toutiao



Table 3: Relative increases of first click ratios by Unbiased LambdaMART in online A/B testing.

Measure	Click@1	Click@3	Click@5
Increase	2.64%	1.21%	0.80%
P-value	0.001	0.004	0.023

検索エンジンのバイアス除去に関して

手前味噌ですが、私のblogやslideに具体的な議論の紹介があります

Speakerdeck (自前)

- <https://speakerdeck.com/usaito>

Blog記事 (自前)

- <https://usaito.hatenablog.com/entry/2019/05/21/193537>
- <https://usaito.hatenablog.com/entry/2019/06/16/180532>

バンディットのオフライン評価関連

すでにわかりやすい資料があります

Speakerdeck (by Cyberagent 安井さん)

- <https://speakerdeck.com/housecat442>

NetflixのBlog記事や講演動画

- <https://medium.com/netflix-techblog/artwork-personalization-c589f074ad76>
- <https://www.youtube.com/watch?v=YvIxpO--9UQ>


推薦システムにおけるCFML

Recommendation x Causalityへの注目

推薦周りの5つのトレンドの一つ

Recent Trend in Personalization

A Netflix Perspective @ICML19



Artwork for Stranger Things that each receive over 5% of impressions from our personalization algorithm. Different images cover a breadth of themes in the show to go beyond what any single image portrays.

Trending Now

Some recent trends in approach

1. Deep Learning
2. Causality
3. Bandits & Reinforcement Learning
4. Fairness
5. Experience Personalization

Trend 2: Causality



NETFLIX

推薦のバンディットのオフライン評価

Artwork Personalization at Netflix

Justin Basilico: Recent Trends in Personalization: A Netflix Perspective. Adaptive and Multi-Task Learning Workshop. In ICML 2019.

問題意識

推薦システムに潜在するバイアス

真のRating

アイテム		Horror	Romance	Drama
ユーザー	Horror	5	1	3
	Romance	1	5	3

映画推薦の例

- ユーザー属性
 - Horror Lovers
 - Romance Lovers
- 映画ジャンル
 - Horror ・ Romance ・ Drama

属性とジャンルの組み合わせに依存してratingが決まるとする

推薦システムに潜在するバイアス

真のRating

	Horror	Romance	Drama
Horror	5	1	3
Romance	1	5	3

予測精度は？



Rating予測

	Horror	Romance	Drama
Horror	5	5	3
Romance	5	5	3

右の予測値matrixの精度をMAEでoffline評価したい

推薦システムに潜在するバイアス

観測回数

	Horror	Romance	Drama
Horror	50	50	50
Romance	50	50	50

を使った時のMAE評価値は「**1.25**」
(全てのデータを一様に持つ理想状態)

真

	Horror	Romance	Drama
Horror	5	1	3
Romance	1	5	3

予測精度は？



予測

	Horror	Romance	Drama
Horror	5	5	3
Romance	5	5	3

推薦システムに潜在するバイアス

観測回数

	Horror	Romance	Drama
Horror	100	10	50
Romance	10	100	50

を使った時のMAE評価値は「**0.25**」
(高評価のデータを多く持つ状態)

真

	Horror	Romance	Drama
Horror	5	1	3
Romance	1	5	3

予測精度は？



予測

	Horror	Romance	Drama
Horror	5	5	3
Romance	5	5	3

推薦システムに潜在するバイアス

観測回数

	Horror	Romance	Drama
Horror	100	10	50
Romance	10	100	50

誤差が生じている部分のデータが少なく
予測精度を過大評価してしまっている

真

	Horror	Romance	Drama
Horror	5	1	3
Romance	1	5	3

予測精度は？



予測

	Horror	Romance	Drama
Horror	5	5	3
Romance	5	5	3

分布の偏りは実際に存在する

そもそもアイテムの観測数には大きな違いが見られる

(Most Popular推薦などではこの傾向が顕著)

3つの標準的なデータセットでの検証結果




Figure 2: The distribution of n_i^* (the observed number of interactions with item i) in the three datasets. The items are presented in descending order of n_i^* . The horizontal axis is log scaled for better visualization. In all datasets, the n_i^* distribution is skewed and the user interactions are significantly biased.

分布の偏りは実際に存在する

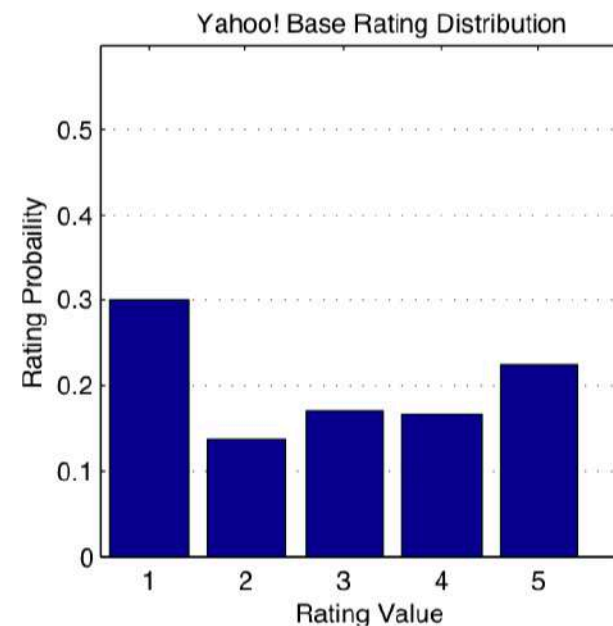
真のrating分布とログデータにおけるrating分布は大きく乖離

実際のrating分布



(a) Yahoo! Survey Rating Distribution

観測されたrating分布



(b) Yahoo! Base Rating Distribution

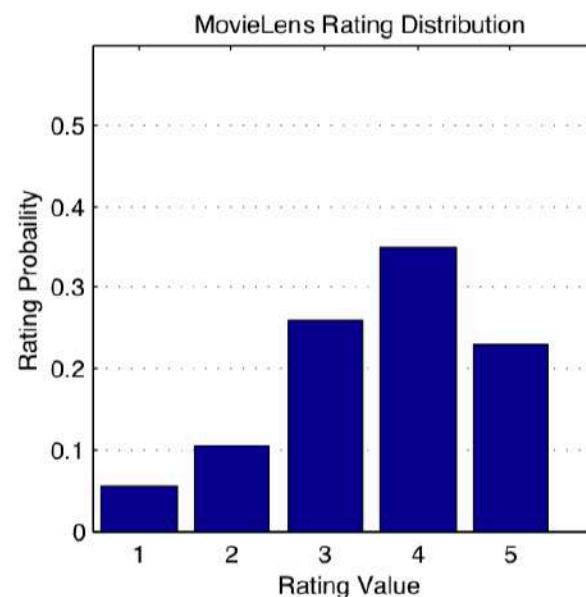
分布の偏りは実際に存在する

Movie Lensは観測された分布しか収録されてないですね..

実際のrating分布



観測されたrating分布



(d) MovieLens Rating Distribution

分布の偏りは実際に存在する

ユーザーは**明確な好き嫌いがあるitemをrateしやすい**

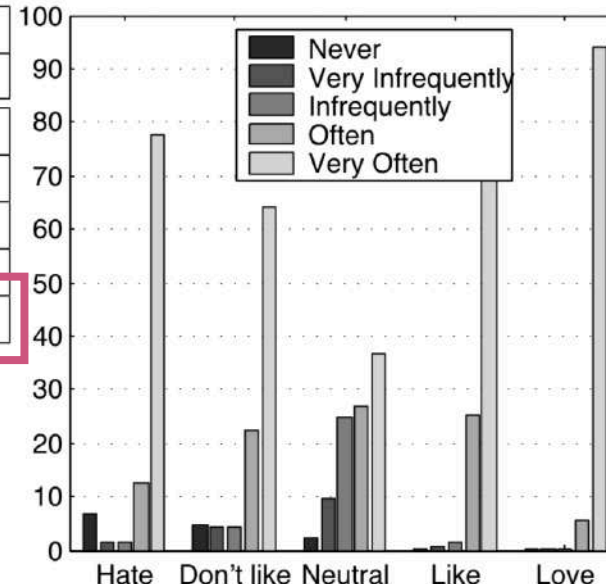
→ 結果として高いratingが観測されやすくなる

選好度合い

rateの
しやすさ

Rating Frequency	Preference Level				
	Hate	Don't like	Neutral	Like	Love
Never	6.76%	4.69%	2.33%	0.11%	0.07%
Very Infrequently	1.59%	4.17%	9.46%	0.54%	0.35%
Infrequently	1.63%	4.44%	24.87%	1.48%	0.20%
Often	12.46%	22.50%	26.83%	25.30%	5.46%
Very Often	77.56%	64.20%	36.50%	72.57%	93.91%

Survey Results: Yahoo! LaunchCast users were asked to report the frequency with which they choose to rate a song given their preference for that song. The data above show the distribution over rating frequencies given several preference levels. Users could select only one rating frequency per preference level.



ここまでのまとめ

推薦システムで観測されるデータは、

- 自分たちが使っていた「過去の推薦方策」
- ユーザーによる「rating付与の自己選択」

という大きく2つの要因により、実際の分布と乖離している

“分布の乖離”をどう扱うかが主要な議論

分布の乖離の補正方法

推薦システムの学習・評価の定式化

ratingの予測値集合 $\hat{Y} = \left\{ \hat{Y}_{u,i} \right\}_{(u,i)}$ の**真の損失**を次のように定義する

$$\mathcal{L}(\hat{Y}) = \frac{1}{U \cdot I} \sum_{u,i} \underbrace{loss \left(Y_{u,i}, \hat{Y}_{u,i} \right)}_{\text{局所損失}}$$

全ユーザーとアイテムにおける平均
(テスト環境は離散一様分布と想定)

Recommendation x Causalityの目標

その上で達成したい目標は、

自分の持っている分布 を用いてalgorithmが
過去のpolicy等に依存した観測データ

workしてほしい分布 における損失の正確な推定
(今回は) 離散一様なユーザー・アイテム分布

- 評価の場合： **真の損失の推定値**を用いて予測の良さを評価する
- 学習の場合：モデルパラメータ更新毎に**真の損失を推定**

観測データの定式化

観測有無を表す確率変数 $O_{u,i}$ を導入 (観測構造に依らない定式化)

観測されるデータは $\{(u, i, Y_{u,i}) : O_{u,i} = 1\}$ と表される

損失を単に平均する **Naive推定量** がよく使われていると思われる

$$\hat{\mathcal{L}}_{naive}(\hat{Y}) = \frac{1}{\sum_{u,i} O_{u,i}} \sum_{(u,i): O_{u,i}=1} \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right)$$

観測されたデータ

バイアスの原因 (Propensity Overfitting)

Naive推定量の期待値をとると...

$$\begin{aligned}\mathbb{E}_O \left[\hat{\mathcal{L}}_{\text{naive}}(\hat{Y}) \right] &= \mathbb{E}_O \left[\frac{1}{N} \sum_{u,i} O_{u,i} \cdot \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right) \right] \\ &= \frac{1}{N} \sum_{u,i} \mathbb{E}_{O_{u,i}} [O_{u,i}] \cdot \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right) \\ &\neq \underbrace{\frac{1}{N} \sum_{u,i} \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right)}_{\mathcal{L}(\hat{Y})} \quad \left. \vphantom{\frac{1}{N} \sum_{u,i} \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right)} \right\} \text{biased!!}\end{aligned}$$

バイアスの発生原因

Naive推定量の期待値をとると...

$$\mathbb{E}_O \left[\hat{\mathcal{L}}_{\text{naive}}(\hat{Y}) \right] = \mathbb{E}_O \left[\frac{1}{N} \sum_{u,i} O_{u,i} \cdot \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right) \right]$$

(暗黙のうちに)
観測確率で重み付けた
評価や学習に陥ってしまう

$$= \frac{1}{N} \sum_{u,i} \underline{\mathbb{E}_{O_{u,i}} [O_{u,i}]} \cdot \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right)$$

観測確率 = 傾向スコア

Inverse Propensity Score (IPS)

観測確率による暗黙の重み付けを回避するために、
あらかじめデータの観測確率の逆数で損失を重み付けておく

損失に対するIPS推定量 [Schnabel et al., ICML2016]

$$\hat{\mathcal{L}}_{IPS}(\hat{Y}) = \frac{1}{U \cdot I} \sum_{\substack{(u,i): O_{ui}=1}} \frac{\text{loss}(Y_{u,i}, \hat{Y}_{u,i})}{\underline{P_{u,i}}}$$

観測データのみで構成 傾向スコア

IPS推定量は不偏性を満たす

IPS推定量の期待値をとると...


$$\begin{aligned}\mathbb{E}_O \left[\hat{\mathcal{L}}_{IPS}(\hat{Y}) \right] &= \mathbb{E}_O \left[\frac{1}{U \cdot I} \sum_{u,i} O_{u,i} \cdot \frac{\text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right)}{P_{u,i}} \right] \\ &= \frac{1}{U \cdot I} \sum_{u,i} \frac{\mathbb{E}_{O_{u,i}} [O_{u,i}]}{P_{u,i}} \cdot \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right) \\ &= \frac{1}{U \cdot I} \sum_{u,i} \text{loss} \left(Y_{u,i}, \hat{Y}_{u,i} \right) = \underline{\mathcal{L}(\hat{Y})} \\ &\quad \text{unbiased!!}\end{aligned}$$

**Biasの観点では
IPS推定量を使うべき**

実験：分布の乖離補正に意味はあるか？


TrainとTestの分布が異なるYahoo! R3データを用いて学習

実際のrating分布



(a) Yahoo! Survey Rating Distribution

観測されたrating分布




(b) Yahoo! Base Rating Distribution

実験: NaiveなMFは過学習

TrainとTestの分布が異なるYahoo! R3データを用いて学習

Train (薄) と Test(濃) におけるMSE




NaiveなMFは学習の
途中から**Test lossのみ悪化**

[Schnabel et al., ICML2016]の追試

実験: IPSに基づいたMFは過学習を軽減

TrainとTestの分布が異なるYahoo! R3データを用いて学習

Train (薄) と Test(濃) におけるMSE



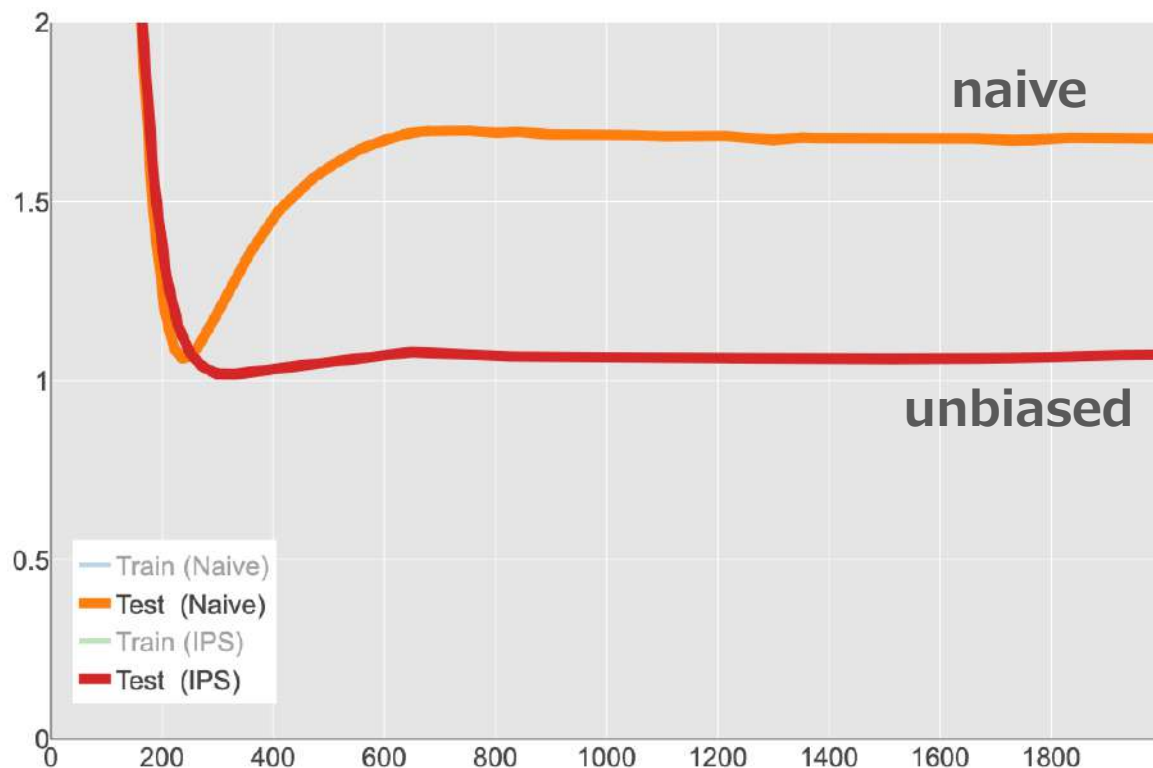
UnbiasedなMFはTestとは
分布の異なる**Trainデータ**を
うまく補正しながら学習

[Schnabel et al., ICML2016]の追試

実験: IPSに基づいたMFは過学習を軽減

TrainとTestの分布が異なるYahoo! R3データを用いて学習

Train (薄) と Test(濃) におけるMSE



汎化性能の違いは
一目瞭然

[Schnabel et al., ICML2016]の追試

最後に

まとめ

細かい手法の議論よりも思想的な部分が重要だと思ってます

- 何で最適化するか（neural netとか？）の前に
何を最適化するかを議論すべき（何も始まらないですよね？）
- そのために、（自分にとっての）**真の損失とは何か？**
それをいかに観測可能なデータから推定すべきか？を意識すべき

ご静聴ありがとうございました！

References

[Schnabel et al., 2016]: Tobias Schnabel, Adith Swaminathan, Ashudeep Singh, Navin Chandak, and Thorsten Joachims. Recommendations as treatments: Debiasing learning and evaluation. In *Proceedings of the 33rd International Conference on International Conference on Machine Learning - Volume 48*, ICML'16, pages 1670–1679, 2016.

[Bonner et al., 2018]: Stephen Bonner and Flavian Vasile. Causal embeddings for recommendation. In *Proceedings of the 12th ACM Conference on Recommender Systems*, pages 104–112. ACM, 2018.

[Liang et al., 2016]: Dawen Liang, Laurent Charlin, James McInerney, and David M Blei. Modeling user exposure in recommendation. In *Proceedings of the 25th International Conference on World Wide Web*. 951–961.

[Wang et al., 2018]: Yixin Wang, Dawen Liang, Laurent Charlin, David M Blei. The deconfounded recommender: A causal inference approach to recommendation. arXiv preprint arXiv:1808.06581 .

[Yang et al., 2018]: Longqi Yang, Yin Cui, Yuan Xuan, Chenyang Wang, Serge Belongie, and Deborah Estrin. 2018. Unbiased Offline Recommender Evaluation for Missing- Not-At-Random Implicit Feedback. In *Twelfth ACM Conference on Recommender Systems (RecSys'18)*

[Marlin et al., 2007]: Benjamin M. Marlin, Richard S. Zemel, Sam Roweis, and Malcolm Slaney. Collaborative filtering and the missing at random assumption. In *UAI*, pp. 267–275, 2007.

References

- [Joachims et al. WSDM2017]: Thorsten Joachims, Adith Swaminathan, and Tobias Schnabel. 2017. Unbiased learning-to-rank with biased feedback. In Proceedings of the 10th ACM International Conference on Web Search and Data Mining (WSDM '17).
- [Wang et al. WSDM2018]: Xuanhui Wang, Nadav Golbandi, Michael Bendersky, Donald Metzler, and Marc Najork. 2018. Position Bias Estimation for Unbiased Learning to Rank in Personal Search. In Proceedings of the 11th ACM International Conference on Web Search and Data Mining (WSDM '18).
- [Ai et al. SIGIR2018]: Qingyao Ai, Keping Bi, Cheng Luo, Jiafeng Guo, and W. Bruce Croft. Unbiased learning to rank with unbiased propensity estimation. In The 41st International ACM SIGIR Conference on Research & Development in Information Retrieval (SIGIR'18).
- [Agarwal et al. WSDM2019]: Aman Agarwal, Ivan Zaitsev, Xuanhui Wang, Cheng Li, Marc Najork and Thorsten Joachims. 2019. Estimating Position Bias without Intrusive Interventions. In The 12th ACM International Conference on Web Search and Data Mining (WSDM '19)
- [Hu et al. WWW2019]: Ziniu Hu and Yang Wang, Qu Peng, Hang Li. 2019. Unbiased LambdaMART: An Unbiased Pairwise Learning-to-Rank Algorithm. In Proceedings of the 2019 World Wide Web Conference (WWW '19)
- [Agarwal et al. WWW2019]: Aman Agarwal, Xuanhui Wang, Cheng Li, Mike Bendersky, and Marc Najork. 2019. Addressing Trust Bias for Unbiased Learning-to-Rank. In Proceedings of the 2019 World Wide Web Conference (WWW '19)
- [Fang et al. SIGIR2019] Fang, Z., Agarwal, A., and Joachims, T. Intervention harvesting for context-dependent examination-bias estimation. arXiv preprint arXiv:1811.01802, 2018.