

Unbiased Recommender Learning from Biased Implicit Feedback



CFML勉強会#4(公開版資料)

19/12/23 (Mon)

齋藤 優太

イントロダクション

推薦システムのバイアス除去関連の盛り上がり

情報検索・推薦系のTop Conferenceで高く評価



Best Paper Honorable Mentions

Unsubscription: A Simple Way to Ease Overload in Email

Iftah Gamzu, Liane Lewin-Eytan and Natalia Silberstein

Offline A/B testing for recommender systems

Alexandre Gilotte, Clement Calauzenes, Thomas Nedelec, Alexandre Abraham and Simon Dolle

推薦システムのオフライン評価

2018

- Causal Embeddings for Recommendation
by S. Bonner, F. Vasile (Best Long Paper)
- Generation Meets Recommendation: Proposing Novel Items for Groups of Users
by T.V. Vo, H. Soh (Best Long Paper Runner-up)




オフライン学習アルゴリズム

推薦システムのバイアス除去関連の盛り上がり

推薦周りの5つのトレンドの一つ

Recent Trend in Personalization A Netflix Perspective @ ICML'19



Trending Now

Some recent trends in approaching the

1. Deep Learning
2. Causality
3. Bandits & Reinforcement Learning
4. Fairness
5. Experience Personalization

NETFLIX

Trend 2: Causality

推薦のバンディットのオフライン評価

Artwork Personalization at Netflix

Why Implicit Feedback?

- 先の例などExplicit Feedbackのバイアス除去は研究が蓄積されつつある
 - CFML勉強会 #1でもExplicit Feedbackを用いた時のバイアス除去の話をした
- しかし現実的に活用可能なデータのほとんどはImplicit Feedback
- にも関わらず不偏推定アプローチは2019年時点で皆無...

つまり、

- かなり実用的な問題設定でインパクトが大きそう
- 未だきちんと解かれた例はなし
- Matrix Factorizationの実装でほぼ十分

今日の流れ

- Implicit Feedbackの定式化
 - ExplicitとImplicit Feedbackの概念的・定式的な違い
 - Exposure Model (*Liang et al., WWW'16*) によるImplicit Feedbackの定式化
- 既存手法の紹介
 - **Weighted Matrix Factorization** (*Hu et al., ICDM'08*)
 - **Bayesian Personalized Ranking** (*Rendle et al., UAI'09*)
 - **Exposure Matrix Factorization** (*Liang et al., WWW'16*)
- Unbiased Recommender Learning
 - **Relevance Matrix Factorization** (*Saito et al., WSDM'20*)
 - **Unbiased Bayesian Personalized Ranking** (*Saito, NeurIPS'19 CausaML WS*)

Implicit Feedbackの 定式化

推薦システムの目的

それぞれのUserに対し**関連性(R)**があるItemを推薦したい

例)あるUserに対して3つのItemをレコメンドするとき (Top-3推薦)

| 推薦有無 | Recommender 1 | Recommender 2 |
|------|---------------|---------------|
| 有 | R=1 | R=0 |
| 有 | R=1 | R=1 |
| 有 | R=1 | R=0 |
| ---- | ---- | ---- |
| 無 | R=0 | R=1 |
| 無 | R=0 | R=1 |

Recommender 1のように
RelevantなItemをTop-Kリストに入れたい



- User-ItemペアのRelevanceを予測
- Relevanceの順位を正確に並べることが重要

理想的な損失関数 (Pointwise)

Pointwise Lossは最も単純な損失の設計方法でRelevanceを点予測する

Relevanceに対して最適化したいので**損失はRelevanceを用いて定義されるべき**

$$\mathcal{L}_{ideal}^{point}(\hat{R}) = \frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} \left[R_{u,i} \delta^{(1)}(\hat{R}_{u,i}) + (1 - R_{u,i}) \delta^{(0)}(\hat{R}_{u,i}) \right]$$

user-itemのrelevanceを表す2値変数

例えば以下のような関数を用いるとbinary cross-entropy lossとなる

$$\delta^{(1)}(\hat{R}_{u,i}) = \log(\hat{R}_{u,i}), \quad \delta^{(0)}(\hat{R}_{u,i}) = \log(1 - \hat{R}_{u,i})$$

理想的な損失関数 (Pairwise)

Top-Kリストを作るにあたってRelevanceを知っている必要は必ずしもない
よってアイテムを双対比較するPairwise Lossもよく用いられる

$$\mathcal{L}_{ideal}^{pair}(\widehat{\mathbf{X}}) = \frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} R_{u,i} (1 - R_{u,j}) \ell(\widehat{X}_{uij})$$

選好順序がついているデータの $R_{u,i} (1 - R_{u,j}) = 1 \Rightarrow i \succ j$ for u

予測スコアの差に対して損失を換算 $\widehat{X}_{uij} = score(u, i) - score(u, j)$

安価に手に入るImplicit Feedback

理想的な損失関数を計算するためにはRelevance情報が必要不可欠

しかし、Relevanceの情報はなかなか手に入らない(annotationが必要)

一方で、Click (Implicit Feedback)の情報は安価に大量に手に入る

$$Y_{u,i}$$

をImplicit Feedbackとする (e.g., click有無, 閲覧有無)

- userの自然な行動履歴
- 能動的に好き嫌いを表したものではない
- 多くの実サービスで安価に手に入る情報

Implicit Feedbackを使って良いレコメンドを達成したいというのはTech企業でよくあるモチベーション(なはず)

観測されるFeedbackをそのまま突っ込んで良いのか？

Implicit FeedbackをそのままRelevanceの代わりに用いることで
ナイーブには次のような損失関数を考えられそう... だけどこれで良いんだっけ？

ナイーブ
pointwise

$$\frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} \left[Y_{u,i} \delta_{u,i}^{(1)} + (1 - Y_{u,i}) \delta_{u,i}^{(0)} \right]$$

Relの部分をクリックにそのまま入れ替えて大丈夫？

ナイーブ
pairwise

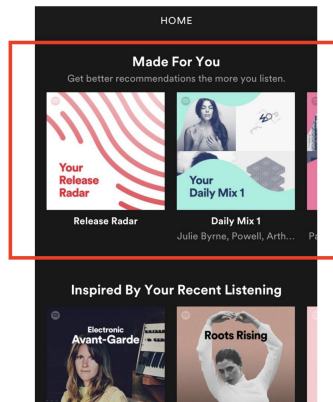
$$\frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} Y_{u,i} (1 - Y_{u,j}) \ell_{u i j}$$

Implicit Feedback \neq Relevance

例) あるUserにMost Popular基準によるTop-2推薦をした場合

| アイテム 人気順位 | 推薦有無 | Relvance (R) | ??? | Click (Y) |
|--------------|------|-----------------|------|--------------|
| 1 | 有 | R=1 | | Y=1 |
| 2 | 有 | R=0 | | Y=0 |
| ---- | ---- | ---- | ---- | ---- |
| 100 | 無 | R=1 | | Y=0 |
| 500 | 無 | R=1 | | Y=0 |
| 1000 | 無 | R=0 | | Y=0 |

Spotifyのホーム画面



Relevance

= Click (implicit feedback)

とは言えなさそう...



損失設計において
特別な対処が必要

Exposure Modelの導入 (Liang et al., WWW'16)

RelevanceとClickの間に次の関係を仮定する

Relevance (関連性)の有無

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Interaction (Click)の有無

Exposure (暴露・認知)の有無

User-Itemに関連性がありかつItemがUserに暴露されていればInteractionが発生
(そして, Interactionが発生するのはその時のみ)

Exposure Modelの導入 (Liang et al., WWW'16)

RelevanceとClickの間に次の関係を仮定する

$$\underbrace{P(Y_{u,i} = 1)}_{\text{click prob}} = \underbrace{P(O_{u,i} = 1)}_{\text{exposure prob}} \cdot \underbrace{P(R_{u,i} = 1)}_{\text{relevance level}}$$
$$= \theta_{u,i} \cdot \gamma_{u,i}$$

Click確率は, Exposure確率とRelevance度合いの積に分解される
(未観測交絡因子は存在しない, と同等)

Implicit Feedback \neq Relevance

例) あるUserにMost Popular基準によるTop-2推薦をした場合

| アイテム 人気順位 | 推薦有無 | Relvance (R) | Exposure (O) | Click (Y) |
|--------------|------|-----------------|-----------------|--------------|
| 1 | 有 | R=1 | O=1 | Y=1 |
| 2 | 有 | R=0 | O=1 | Y=0 |
| ---- | ---- | ---- | ---- | ---- |
| 100 | 無 | R=1 | O=0 | Y=0 |
| 500 | 無 | R=1 | O=0 | Y=0 |
| 1000 | 無 | R=0 | O=0 | Y=0 |

実はExposure変数を入れると
綺麗に説明がつく

Click情報のみを使って
Relevanceを当てる問題

2つの大きな困難が存在

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Positive-Unlabeled Problem

Implicit Feedbackを扱うために対処すべき問題点をExposure Modelから説明

まずImplicit Feedbackに固有の問題として**Positive-Unlabeled Problem**がある

$$Y_{u,i} = 0 \Rightarrow O_{u,i} = 0 \text{ or } R_{u,i} = 0$$

つまり、Clickが観測されなかった場合 ($Y=0$)、**それが気づかれなかったから($O=0$)なのか興味がなかったから($R=0$)なのかがわからない**

そのため、 **$Y=0$ はNegativeではなくUnlabeled Feedback**である

Missing-Not-At-Random Problem

Implicit Feedbackを扱うために対処すべき問題点をExposure Modelから説明

またExplicit Feedbackの場合にも発生する**Missing-Not-At-Random Problem**

$$P(Y_{u,i} = 1) = P(O_{u,i} = 1) \cdot P(R_{u,i} = 1)$$

$$P(O_{u,i} = 1) = P(Y_{u,i} = 1 \mid R_{u,i} = 1)$$

すなわち、RelevantなペアのClickがちゃんと観測される確率

ここは**通常一様ではなく**、PopularなItemのClickが観測されやすかったりする

Missing-Not-At-Random Problem

Implicit Feedbackを扱うために対処すべき問題点をExposure Modelから説明

またExplicit Feedbackの場合にも発生する**Missing-Not-At-Random Problem**




Figure 2: The distribution of n_i^* (the observed number of interactions with item i) in the three datasets. The items are presented in descending order of n_i^* . The horizontal axis is log scaled for better visualization. In all datasets, the n_i^* distribution is skewed and the user interactions are significantly biased.

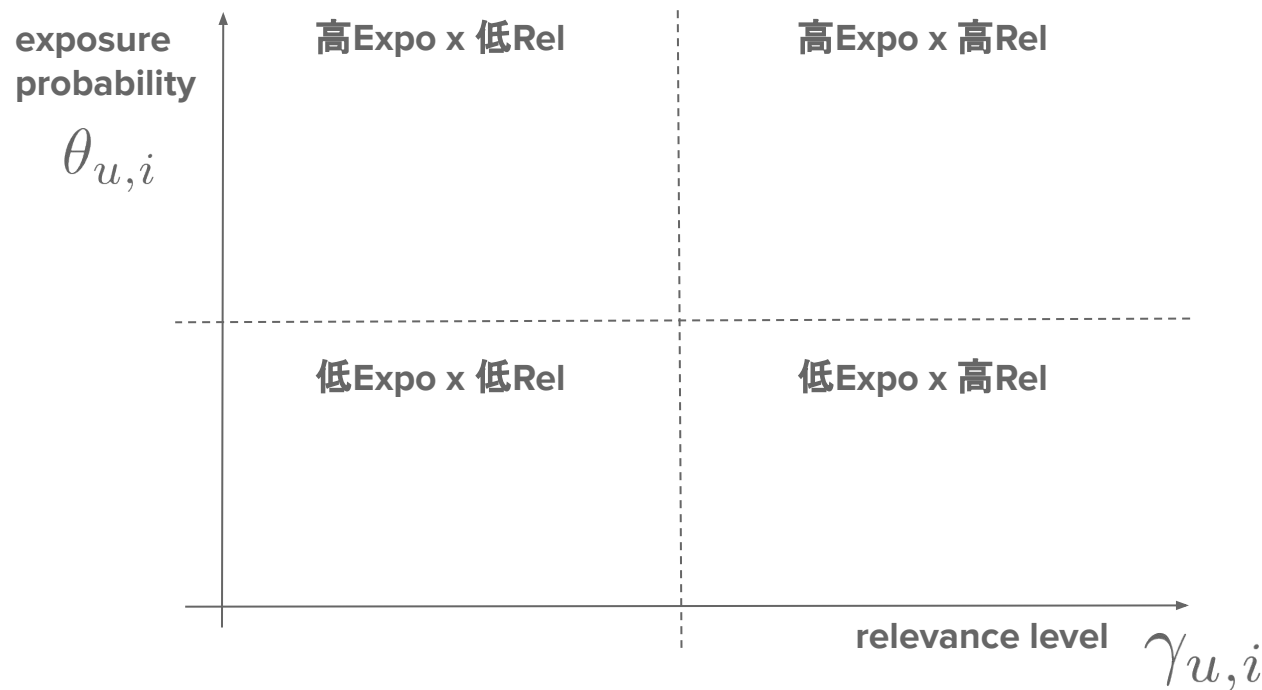
Yang et al. (2018)

すなわち、RelevantなペアのClickがちゃんと観測される確率

ここは**通常一様ではなく**、PopularなItemのClickが観測されやすかったりする

Implicit Feedback問題の視覚的解釈

Implicit Feedbackの問題設定を視覚的に理解してみる

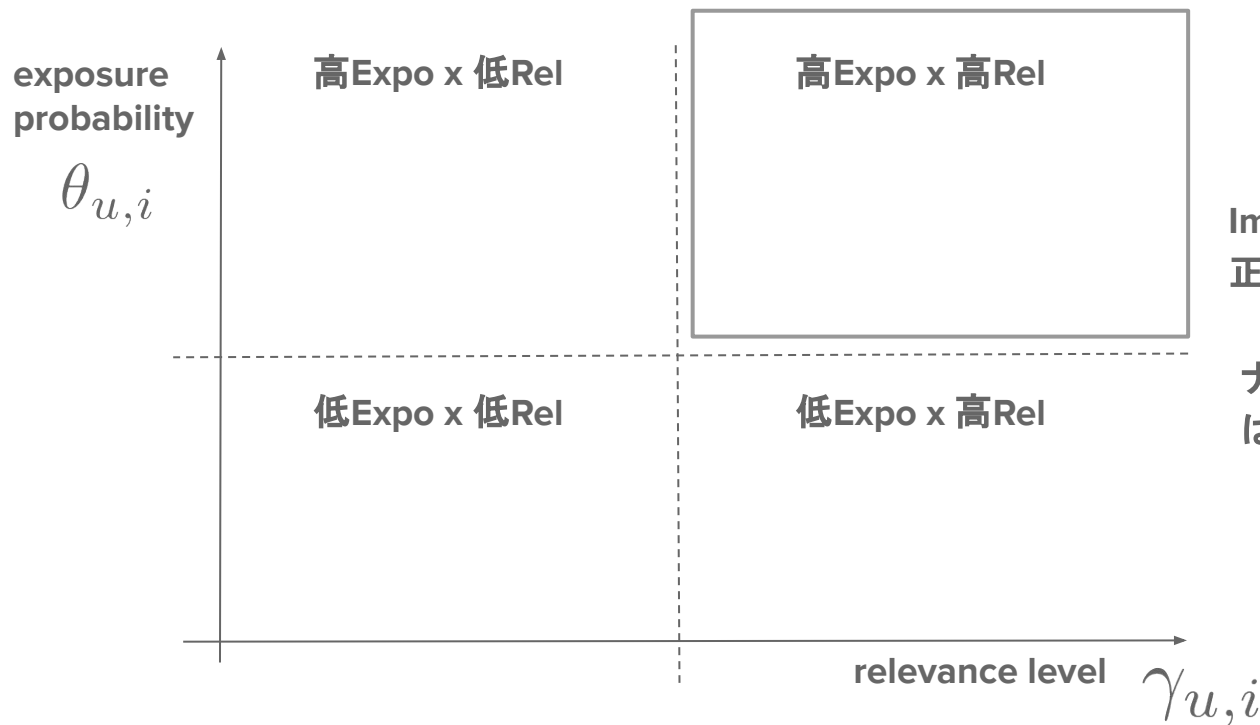


Exposure model

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Implicit Feedback問題の視覚的解釈

Implicit Feedbackの問題設定を視覚的に理解してみる



Exposure model

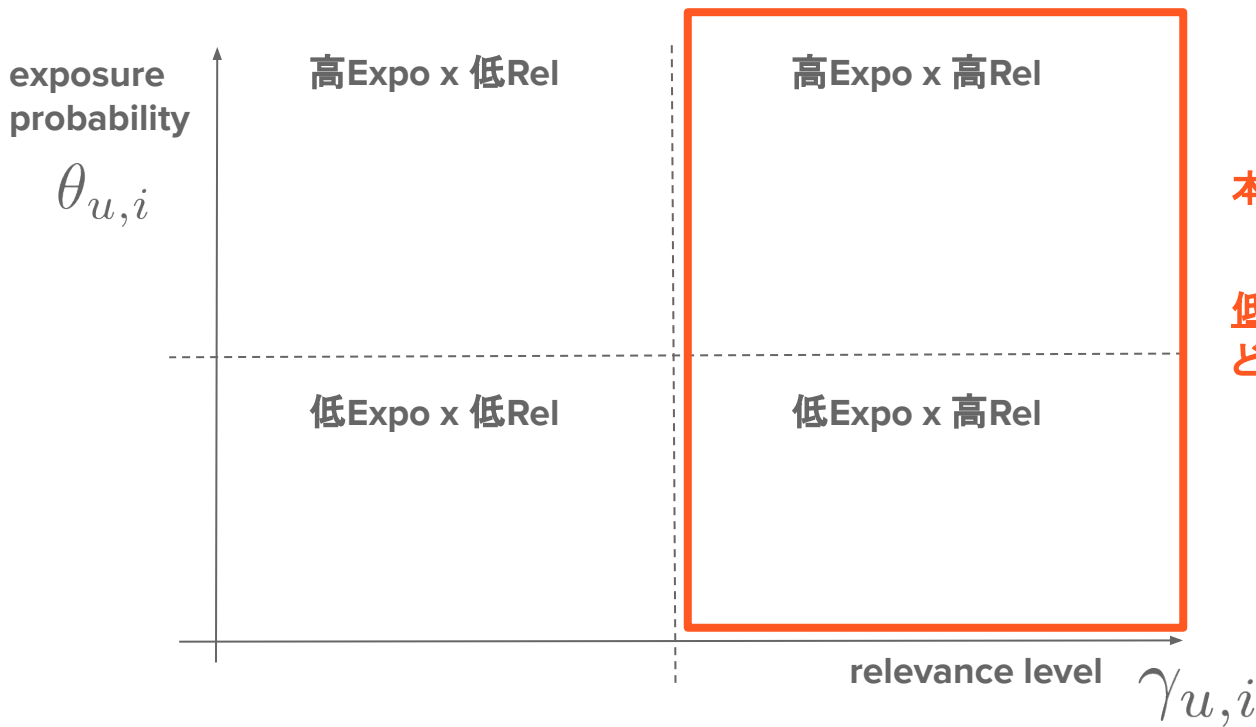
$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Implicit Feedbackにおいて
正例として観測される部分

ナイーブにYを予測するモデル
はここを識別境界とする

Implicit Feedback問題の視覚的解釈

Implicit Feedbackの問題設定を視覚的に理解してみる



Exposure model

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

本当は正例として見なしたい部分

低Expo x 高Relを抽出するには
どのlossを最適化すれば良いか？

既存手法の紹介と整理

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Weighted Matrix Factorization (WMF)

- WMF (*Hu et al., ICDM'08*) は, Implicit Feedbackにおける最もベーシックな手法
- WMFは***Ideal Pointwise Loss***に対する次の推定量を最適化する

$$\hat{\mathcal{L}}_{WMF}(\hat{R}) = \frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} \left[c Y_{u,i} \delta_{u,i}^{(1)} + (1 - Y_{u,i}) \delta_{u,i}^{(0)} \right]$$

- Clickが発生しているデータ ($Y=1$) を一様に定数 c (≥ 1) で重み付け
- Clickが発生していれば必ずRelevantだから? $Y = 1 \Rightarrow R = 1$

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Bayesian Personalized Ranking (BPR)

- BPR (Rendle et al., UAI'09) は最もベーシックなPairwise手法
- BPRは***Ideal Pairwise Loss***に対する次の推定量を最適化する

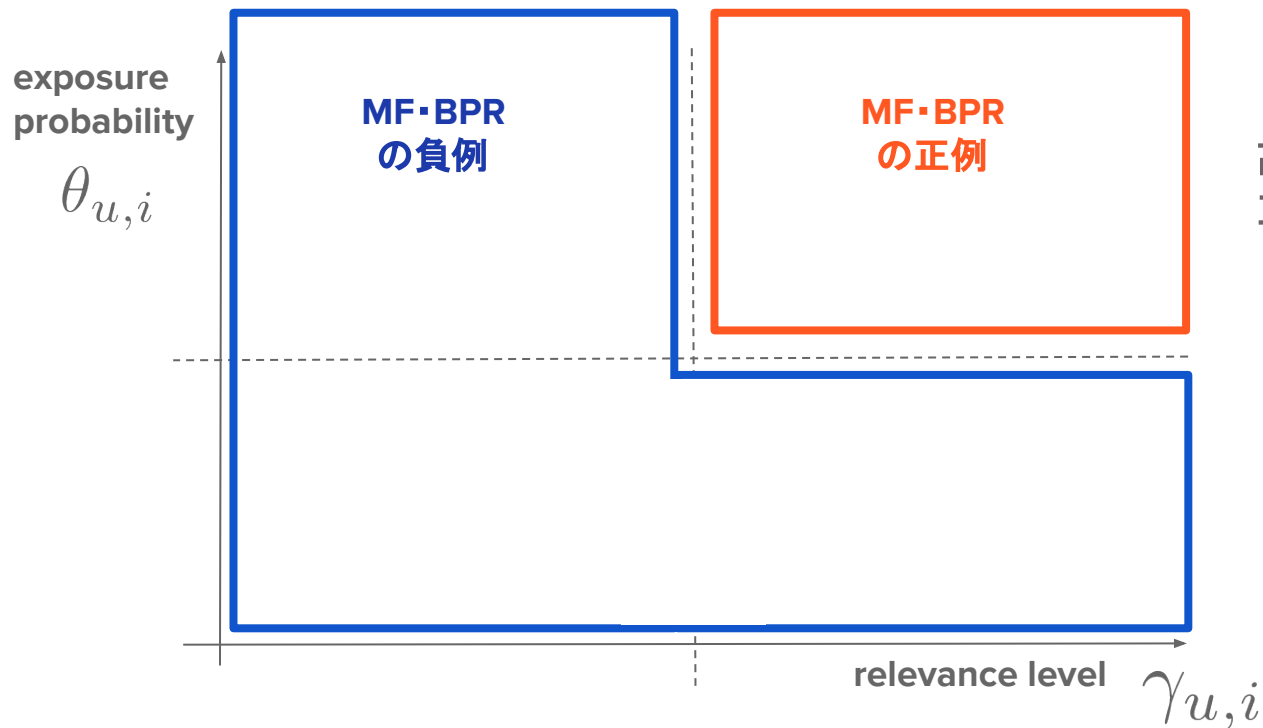
$$\hat{\mathcal{L}}_{BPR}(\hat{\mathbf{X}}) = \frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} Y_{u,i} (1 - Y_{u,j}) \ell_{uij}$$

- Clickデータ (Y=1)を正例、Unclickデータ (Y=0)を単に負例として扱う
- もちろんY=0のなかにもRel=1が含まれるため

Positive-Unlabeled問題に取り組めていない

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

MF・BPR Estimatorの視覚的解釈



高Expo x 高Relデータのみを
正例として扱う



Positive-Unlabeledの問題
に取り組めていない

$$\mathbb{E} \left[\hat{\mathcal{L}}_{WMF}(\hat{R}) \right] \neq \mathcal{L}_{ideal}^{point}(\hat{R})$$

$$\mathbb{E} \left[\hat{\mathcal{L}}_{BPR}(\hat{X}) \right] \neq \mathcal{L}_{ideal}^{pair}(\hat{X})$$

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Exposure Matrix Factorization (ExpoMF)

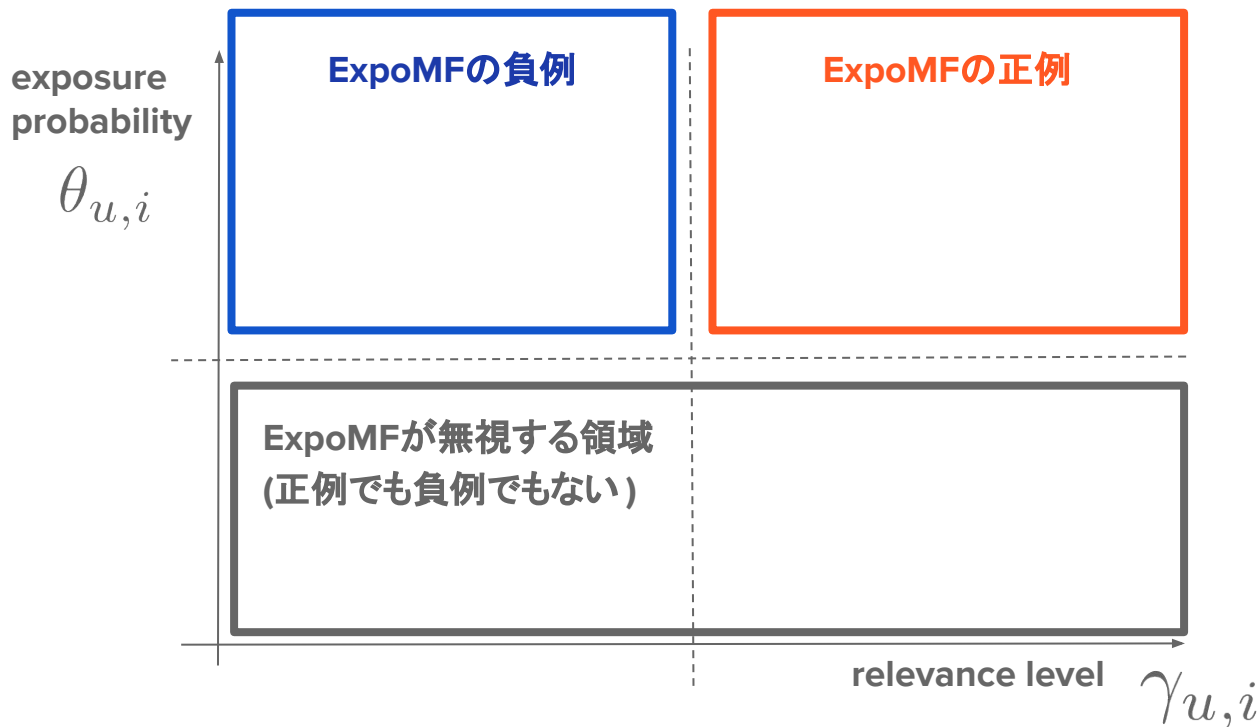
- ExpoMF (Liang et al., WWW'16) は, **Positive-Unlabeled**の問題に取り組んだ
- ExpoMFは***Ideal Pointwise Loss***に対する次の推定量を最適化する

$$\hat{\mathcal{L}}_{ExpoMF} = \frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} \theta'_{u,i} \left[Y_{u,i} \delta_{u,i}^{(1)} + (1 - Y_{u,i}) \delta_{u,i}^{(0)} \right]$$

- 各データをPosterior Exposure Probabilityで重み付け $\theta'_{u,i} = \mathbb{E} [O_{u,i} | Y_{u,i}]$
- Expo = 1ならば, Click = Relだから $O_{u,i} = 1 \Rightarrow Y_{u,i} = R_{u,i}$

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

ExpoMF Estimatorの視覚的解釈



ExpoMFは高Expo x 高Relを正例
高Expo x 低Relを負例として扱うが 低
Expoデータは一律に扱う



Missing-Not-At-Randomの問題
に取り組めていない

$$\mathbb{E} \left[\hat{\mathcal{L}}_{ExpoMF}(\hat{R}) \right] \neq \mathcal{L}_{ideal}^{point}(\hat{R})$$

提案手法の紹介と整理

Relevance Matrix Factorization (Rel-MF)

- Rel-MF (*Saito et al., WSDM'20*) は初めてUnbiasedな推定量を採用
- Rel-MFは***Ideal Pointwise Loss***に対する次の推定量を最適化する

$$\hat{\mathcal{L}}_{unbiased}^{point}(\hat{R}) = \frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} \left[\frac{Y_{u,i}}{\theta_{u,i}} \delta_{u,i}^{(1)} + \left(1 - \frac{Y_{u,i}}{\theta_{u,i}} \right) \delta_{u,i}^{(0)} \right]$$

- Click発生有無のindicatorをExpo確率の逆数で重み付ける (低Expoに大きな重み)
- Exposureのindicatorである0が推定量に現れないため

ExplicitのときのInverse Propensity Score (IPS)とは異なる推定量

Relevance Matrix Factorization (Rel-MF)

- Rel-MF (Saito et al., WSDM'20) は初めてUnbiasedな推定量を採用
- Rel-MFは***Ideal Pointwise Loss***に対する次の推定量を最適化する

$$= \frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} \left[\underbrace{Y_{u,i} \left(\frac{\delta_{u,i}^{(1)}}{\theta_{u,i}} + \left(1 - \frac{1}{\theta_{u,i}} \right) \delta_{u,i}^{(0)} \right)}_{\text{click発生データに対する loss}} + \underbrace{(1 - Y_{u,i}) \delta_{u,i}^{(0)}}_{\text{click未発生データに対する loss}} \right]$$

- Clickデータに対してpositive lossとnegative lossの両方を適用
- Unclickデータに対してはnegative lossをそのまま適用

Relevance Matrix Factorization (Rel-MF)

- Rel-MF (Saito et al., WSDM'20) は初めてUnbiasedな推定量を採用
- Rel-MFは***Ideal Pointwise Loss***に対する次の推定量を最適化する

$$= \frac{1}{|\mathcal{D}|} \sum_{(u,i) \in \mathcal{D}} \left[Y_{u,i} \left(\frac{\delta_{u,i}^{(1)}}{\theta_{u,i}} + \left(1 - \frac{1}{\theta_{u,i}} \right) \delta_{u,i}^{(0)} \right) + (1 - Y_{u,i}) \delta_{u,i}^{(0)} \right]$$

- Rel-MFの推定量は***Ideal Pointwise Loss***に対して不偏性を持つ

$$\mathbb{E} \left[\hat{\mathcal{L}}_{unbiased}^{point}(\hat{R}) \right] = \mathcal{L}_{ideal}^{point}(\hat{R})$$

Unbiased Bayesian Personalized Ranking (UBPR)

- UBPR (*Saito, NeurIPS'19 CausalML WS*) はRel-MFの推定量をpairへ拡張
- UBPRは***Ideal Pairwise Loss***に対する次の推定量を最適化する

$$\hat{\mathcal{L}}_{unbiased}^{pair}(\hat{\mathbf{X}}) = \frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} \frac{Y_{u,i}}{\theta_{u,i}} \left(1 - \frac{Y_{u,j}}{\theta_{u,j}} \right) \ell_{uij}$$

- 2つのアイテムに対してClick発生有無のindicatorを
Expo確率の逆数で重み付ける (低Expoに大きな重み)

Unbiased Bayesian Personalized Ranking (UBPR)

- UBPR (*Saito, NeurIPS'19 CausalML WS*) はRel-MFの推定量をpairへ拡張
- UBPRは***Ideal Pairwise Loss***に対する次の推定量を最適化する

$$= \frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} \frac{Y_{u,i}}{\theta_{u,i}} \left(\underbrace{Y_{u,j} \left(1 - \frac{1}{\theta_{u,j}} \right)}_{\text{click発生アイテム}} + \underbrace{(1 - Y_{u,j})}_{\text{click未発生アイテム}} \right) \ell_{uij}$$

- ナイーブなBPRはclick発生アイテム ($Y=1$)と未発生アイテム($Y=0$)を比べていた
- UBPRはclick発生アイテム同士のペア比較も損失に加算される
(よってデータサンプリング方法がnaive BPRと異なる)

Unbiased Bayesian Personalized Ranking (UBPR)

- UBPR (*Saito, NeurIPS'19 CausalML WS*) はRel-MFの推定量をpairへ拡張
- UBPRは***Ideal Pairwise Loss***に対する次の推定量を最適化する

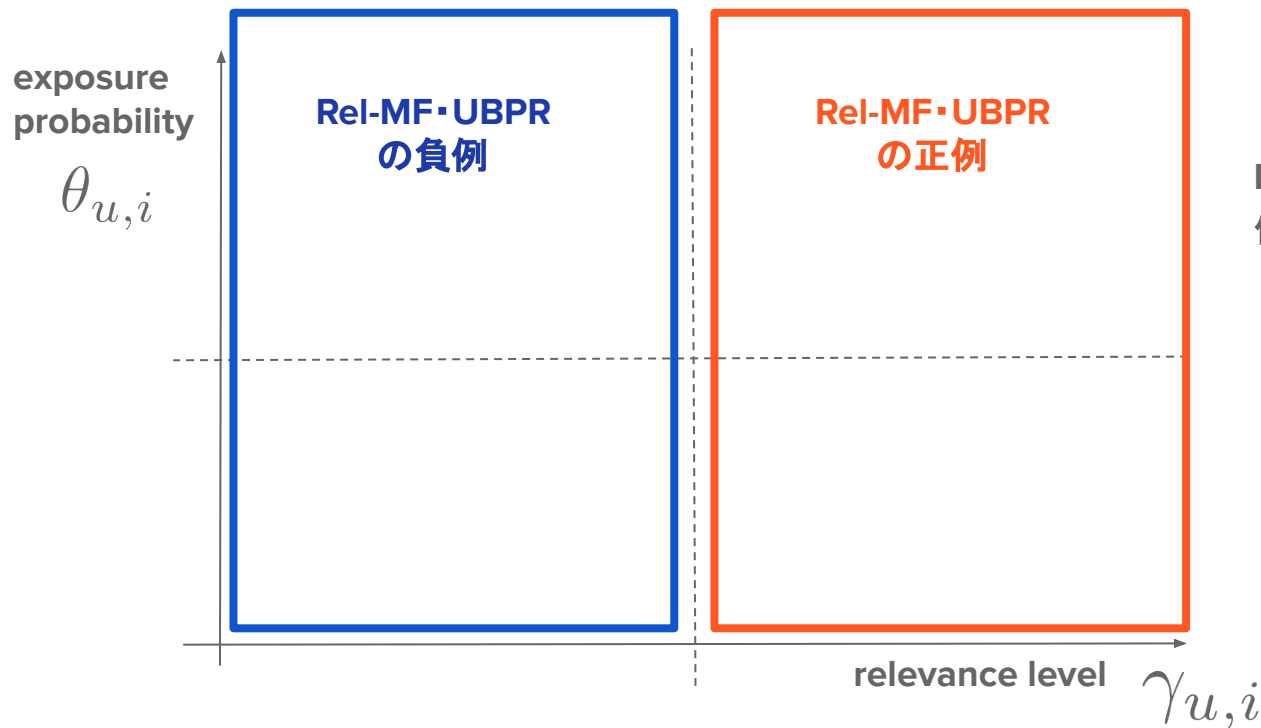
$$= \frac{1}{|\mathcal{D}|} \sum_{(u,i,j) \in \mathcal{D}} \frac{Y_{u,i}}{\theta_{u,i}} \left(\underbrace{Y_{u,j} \left(1 - \frac{1}{\theta_{u,j}} \right)}_{\text{click発生アイテム}} + \underbrace{(1 - Y_{u,j})}_{\text{click未発生アイテム}} \right) \ell_{uij}$$

- UBPRの推定量は***Ideal Pairwise Loss***に対して不偏性を持つ

$$\mathbb{E} \left[\hat{\mathcal{L}}_{unbiased}^{pair}(\hat{X}) \right] = \mathcal{L}_{ideal}^{pair}(\hat{X})$$

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

Unbiased Estimatorsの視覚的解釈



Expo確率の逆数で重み付けるので
低Expoデータも判別可能に



Positive-Unlabeledの問題・
Missing-Not-At-Randomの問題
の両方に取り組めているはず！

既存・提案手法のまとめ

ここまでに登場した5つの手法を3つの観点からざっと整理

| | Approach | Technique | Unbiased? |
|------------------------------|------------------|---------------------------------|------------|
| WMF | Pointwise | Naive | NO |
| BPR | Pairwise | Naive | NO |
| ExpoMF | Pointwise | EM Algorithm | NO |
| Rel-MF (proposed) | Pointwise | Propensity Weighting | YES |
| UBPR (proposed) | Pairwise | Propensity Weighting | YES |

(余談) Exposure確率の推定方法

実は論文では特に議論していないが次の方法を転用できそう

- 単純なItem Popularity (*Yang et al., RecSys'18*) [[解説ブログ記事](#)]
- EM-Algorithm (*Liang et al., WWW'16*)
- Regression-EM (*Wang et al., WSDM'18*)
- Dual Learning Algorithm (*Ai et al., SIGIR'18*)

*実験ではとりあえず楽で既存研究 (*Yang et al., RecSys'18*)でうまくいっている item popularityを使用

**ベーシックなレコメンの設定だと user-itemのimplicit feedback matrixのみが与えられるので

Exposure確率の推定は無理ゲーに近い

Exposure model

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$

(余談) Exposure確率の推定方法

例えば同じimplicit feedbackのバイアス除去が主題の[Unbiased Learning-to-Rank](#)ではランキング構造を利用したモデルを仮定する

Search Engineのexposure
(examination)はpositionに大きく依存



Exposure model (行列の存在のみ)

$$Y_{u,i} = O_{u,i} \cdot R_{u,i}$$



Exposure model (明らかなposition biasの仮定下)

$$Y_{u,i} = O_k \cdot R_{u,i}$$

妥当そうな仮定によりパラメータ数が大幅に減少

On-going & Future work

- とはいものの、(fully) implicit feedbackは観測できる情報が少なすぎて現状実用レベルにはなさそうというのが個人的な印象
(実際はweight clippingやnon-negative lossなどのpracticalなテクを使っている)
- ただし実務上、(fully) implicit feedbackの問題を解かなければならない場面は実はそんなに多くない
- 現在はimplicit feedbackと同じくらいたくさん収集できるがより簡単に活用できるfeedback型に着目した手法を開発中
(実用的にはこのあたりの手法の方を参照していただくのが良いかと)

まとめ

- Explicit FeedbackはRelevanceが直接観測されるので、その観測確率が一様ではないというMNAR問題を排除することが目標([CFML勉強会#1の資料](#))
- 一方でImplicit FeedbackはMNAR問題に加えてPU問題も解く必要がある
- 既存研究はどれも最適化したいはずの損失に対してbiasがあったので
PointwiseとPairwiseの両方でUnbiasedな損失関数を提案してみた

ご静聴ありがとうございました！

References

- (Liang et al., WWW'16)**: Dawen Liang, Laurent Charlin, James McInerney, and David M Blei. 2016. Modeling user exposure in recommendation. In Proceedings of the 25th International Conference on World Wide Web. International World Wide Web Conferences Steering Committee, 951–961.
- (Saito et al., WSDM'20)**: Yuta Saito, Suguru Yaginuma, Yuta Nishino, Hayato Sakata, and Kazuhide Nakata. 2020. Unbiased Recommender Learning from Missing-Not-At-Random Implicit Feedback. In The Thirteenth ACM International Conference on Web Search and Data Mining (WSDM'20), February 3–7, 2020, Houston, TX, USA. ACM, New York, NY, USA.
- (Saito, NeurIPS'19 CausalML WS)**: Yuta Saito. 2019. Unbiased Pairwise Learning from Implicit Feedback.
- (Saito et al., NeurIPS'19 CausalML WS)**: Yuta Saito, Gota Morishita, and Shota Yasui. 2019. Dual Learning Algorithm for Delayed Feedback in Display Advertising.
- (Hu et al., ICDM'08)**: Yifan Hu, Yehuda Koren, and Chris Volinsky. 2008. Collaborative filtering for implicit feedback datasets. In 2008 Eighth IEEE International Conference on Data Mining. Ieee, 263–272.
- (Schnabel et al., ICML'16)** : Tobias Schnabel, Adith Swaminathan, Ashudeep Singh, Navin Chandak, and Thorsten Joachims. 2016. Recommendations as Treatments: Debiasing Learning and Evaluation. In International Conference on Machine Learning. 1670–1679
- (Rendle et al., UAI'09)** : Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme. 2009. BPR: Bayesian personalized ranking from implicit feedback. In Proceedings of the twenty-fifth conference on uncertainty in artificial intelligence. AUAI Press, 452–461.

References

- (Yang et al., RecSys'18):** Longqi Yang, Yin Cui, Yuan Xuan, Chenyang Wang, Serge Belongie, and Deborah Estrin. 2018. Unbiased offline recommender evaluation for missing-not-atrandom implicit feedback. In Proceedings of RecSys '18. ACM, 279–287.
- (Wang et al., WSDM'18):** Xuanhui Wang, Nadav Golbandi, Michael Bendersky, Donald Metzler, and Marc Najork. 2018. Position Bias Estimation for Unbiased Learning to Rank in Personal Search. In Proc. of the 11th ACM International Conference on Web Search and Data Mining (WSDM). 610–618.
- (Ai et al., SIGIR'18):** Qingyao Ai, Keping Bi, Cheng Luo, Jiafeng Guo, and W Bruce Croft. 2018. Unbiased Learning to Rank with Unbiased Propensity Estimation. In Proc. of the 41st International ACM SIGIR Conference on Research & Development in Information Retrieval (SIGIR). 385–394.
- (Marlin et al., RecSys'09):** Benjamin M Marlin and Richard S Zemel. 2009. Collaborative prediction and ranking with non-random missing data.
- (Bonner et al., RecSys'18):** Causal Embeddings for Recommendation. In Proceedings of the 12th ACM Conference on Recommender Systems (RecSys '18). ACM, New York, NY, USA, 104–112.
- (Wang et al., ICML'19):** Xiaojie Wang, Rui Zhang, Yu Sun, and Jianzhong Qi. 2019. Doubly robust joint learning for recommendation on data missing not at random. In International Conference on Machine Learning, pages 6638–6647.
- (Liang et al., UAI'16 Causal WS):** Dawen Liang, Laurent Charlin, and David M Blei. 2016. In Causation: Foundation to Application, Workshop at UAI.